

5.1: 试述将线性函数  $f(x) = w^T x$  用作神经元激活函数的缺陷。

答: 无论是在隐藏层还是在输出层使用激活函数之前都是关于  $x$  的线性组合, 若仍使用线性函数  $f(x) = w^T x$  作为激活函数, 整个网络都仍等价于线性回归, 达不到“筛选”与“激活”的目的。

5.2: 试述使用图 5.2(b) 激活函数的神经元与对数似然的联系。

答: 相同点: 两者均使用了  $\text{Sigmoid}: y = \frac{1}{1+e^{-x}}$  替代函数

不同之处: 在对数似然回归中, 当  $\text{sigmoid}(x) > 0.5$  时输出为 1 表示正例; 反之为 0, 表示负例。

在 5.2(b) 激活函数中,  $\text{sigmoid}(x)$  即为真实输出值。

$$5.3: \text{证明 } \Delta V_{ih} = -\eta \frac{\partial E_k}{\partial V_{ih}} = -\eta \frac{\partial E_k}{\partial y_j^k} \cdot \frac{\partial y_j^k}{\partial \beta_j} \cdot \frac{\partial \beta_j}{\partial b_n} \cdot \frac{\partial b_n}{\partial z_n} \cdot \frac{\partial z_n}{\partial V_{ih}}$$

$$\text{由于 } \frac{\partial z_n}{\partial V_{ih}} = \sum_{j=1}^L g_j W_{hj} f'(z_n - V_h) \cdot x_i \quad (b_n = f(z_n - V_h))$$

$$\text{由于 } f'(z_n - V_h) = f(z_n - V_h) [1 - f(z_n - V_h)] = b_n (1 - b_n)$$

$$\text{则 } \Delta V_{ih} = \eta \sum_{j=1}^L g_j W_{hj} b_n (1 - b_n) \cdot x_i$$

$$= \eta \cdot b_n (1 - b_n) \sum_{j=1}^L W_{hj} \cdot x_i$$

$$= \eta \cdot e_h \cdot x_i$$

5.4: 学习率太小, 会使每次下降变得越慢, 时间花费时间长, 开销成本大。

学习率太大, 会使每次下降幅度大, 易在最优值附近来回振荡, 可能还达不到最优值。



# 第六章 支持向量机作业

6.1 证明: 设超平面:  $WTx + b = 0$ , 点  $x_0$  为训练点,  $x_0$  为点  $x_0$  到超平面的投影

$$\text{即: } WT x_0 + b = 0$$

则点  $x_0$  到超平面的距离即为  $|x_0 - \bar{x}_0|$  在  $WT$  方向上的投影

$$r = \frac{|WT \cdot (x_0 - \bar{x}_0)|}{||WT||} = \frac{|WT x_0 - WT \bar{x}_0|}{||WT||} = \frac{|b - WT \bar{x}_0|}{||WT||} = \frac{|WT x_0 + b|}{||WT||} \quad \text{证毕}$$

6.4 解: ① 首先应为二分类问题: 因为虽然 LDA 可进行多分类, 但 SVM 只能解决二分类问题。

② 若为硬间隔, 则需为线性可分, 而软间隔则不用。

③ 当 LDA 求出的  $\vec{w}_1$  与 SVM 求出的间隔超平面的  $WT$  相互垂直时, 两者等价。(间隔与线性可分问题)

6.6 解: 由于 SVM 的目的是寻找一个间隔超平面, 取“最大间隔”: 在硬间隔下, 若

事先过多的噪声且噪声分布不均匀, 则可能无法寻找到一个间隔超平面; 而对于软间隔,

噪声可能落入最大间隔之中, 成为支持向量, 影响对间隔超平面的确定, 产生

较大影响。

6.7 解: 满足 KKT 条件:

$$\begin{cases} u_i \xi_i = 0 \\ \hat{u}_i \hat{\xi}_i = 0 \\ \xi_i \geq 0, \hat{\xi}_i \geq 0 \\ u_i \geq 0, \hat{u}_i \geq 0 \\ \alpha_i \geq 0, \hat{\alpha}_i \geq 0 \\ \alpha_i \hat{\alpha}_i = 0, \xi_i \hat{\xi}_i = 0 \\ \alpha_i (y_i - f(x_i) - \epsilon - \xi_i) = 0 \\ \hat{\alpha}_i (y_i - f(\hat{x}_i) - \epsilon - \hat{\xi}_i) = 0 \\ f(x_i) - y_i - \epsilon - \xi_i \leq 0, y_i - f(\hat{x}_i) - \epsilon - \hat{\xi}_i \leq 0 \end{cases}$$